

Sistemi Distribuiti Intelligenti

Controllo, Comunicazione e Stima

Sintesi Analitica e Matematica Rigorosa dal Capitolo 10 al Capitolo 19

Gemini Notebook

Partner di Co-Creazione per Sistemi Distribuiti

August 2026

Contents

1	Introduzione	1
2	Capitolo 10: I Processi di Misura e la Caratterizzazione dell'Incertezza	2
2.1	Definizioni Formali Metrologiche (VIM)	2
2.2	Modellazione Matematica del Sensore e Calibrazione	2
2.3	Valutazione dell'Incertezza secondo la Guida GUM	3
3	Capitolo 11: Fondamenti di Statistica e Propagazione degli Errori	4
3.1	Assiomi di Kolmogorov e Teorema di Bayes	4
3.2	Variabili Casuali, Momenti Statistici e PDF Multidimensionali	4
3.3	Teorema del Limite Centrale e Propagazione degli Errori	5
4	Capitolo 12: Algoritmi di Stima e Approcci Bayesiani	6
4.1	Classificazione dei Problemi di Stima	6
4.2	Proprietà degli Stimatori, CRLB e Fisher Information	6
4.3	Teorema di Gauss-Markov e Stimatore BLUE	7
4.4	Approccio Bayesiano e Caso Gaussiano Multidimensionale	7
5	Capitolo 13: Stimatori Lineari e Non Lineari (Kalman, EKF, UKF)	8
5.1	I Minimi Quadrati Pesati (WLS) Batch e Ricorsivi	8
5.2	Il Filtro di Kalman Lineare (KF)	8
5.2.1	Derivazione Matematica del Guadagno Ottimo	9
5.3	Il Filtro di Kalman Esteso (EKF)	9
5.4	Il Filtro di Kalman Unscented (UKF) e l'Incertezza Polare-Cartesiana	10
6	Capitolo 14: Metodi di Stima Avanzati - Massima Verosimiglianza (MLE)	12
6.1	La Likelihood Function e la Formulazione dell'Ottimo	12
6.2	Esempio Analitico: Distribuzione di Poisson	12
6.3	Proprietà Asintotiche dello Stimatore MLE	13
6.4	Determinazione Numerica dell'Ottimo	13
6.5	Applicazione ai Segnali: Stima dei Parametri di una Sinusoide	13
7	Capitolo 15: Un Esempio di Stima Distribuita e Incoerenza nelle Covarianze	15
7.1	Modellazione e Stima Intermittente	15
7.2	Misure Relative e l'Insorgenza della Correlazione	15
7.3	Incoerenza della Stima e Sottostima dell'Incertezza	16
8	Capitolo 16: Sistemi Digitali e Discretizzazione di Sistemi Continui	17
8.1	Metodi di Discretizzazione di Sistemi Lineari SISO	17
8.2	Risposta Libera, Risposta Forzata e la Discretizzazione dello Stato	17
8.3	Discretizzazione del Rumore di Processo	18
8.4	Campionamento di Riemann e di Lebesgue	18
9	Capitolo 17: Teoria del Consenso Lineare su Grafi	19
9.1	Modellazione Algebrica del Consenso e Matrici Stocastiche	19
9.2	Teoria dei Grafi e Proprietà del Laplaciano	19
9.3	Velocità di Convergenza e Progettazione Ottima dei Pesi	20

10 Capitolo 18: Algoritmi di Stima Distribuita (Distributed WLS e DKF)	21
10.1 Algoritmo dei Minimi Quadrati Pesati Distribuito (D-WLS)	21
10.2 Filtro di Kalman Distribuito (DKF)	21
11 Capitolo 19: Introduzione al Controllo Distribuito	23
11.1 Controllo di Copertura Distribuita mediante Tassellazione di Voronoi	23
11.2 Consenso del Secondo Ordine per Sistemi Posizione-Velocità	24
11.3 Problematiche Reali di Comunicazione nei Sistemi Multi-Agente	24

1 Introduzione

Questo documento costituisce un compendio analitico e matematicamente rigoroso dei contenuti trattati dal Capitolo 10 al Capitolo 19 del corso di **Sistemi Distribuiti Intelligenti** (Intelligent Distributed Systems) per l'Anno Accademico 2023/2024.

L'obiettivo di questa sintesi è fornire una trattazione esaustiva che non si limiti ad esporre i concetti, ma ne ricostruisca le basi matematiche, le derivazioni algoritmiche, i modelli dinamici e le problematiche realizzative di rete. La struttura segue l'architettura logica delle dispense del corso, integrando le definizioni formali del vocabolario metrologico, la propagazione probabilistica dell'errore, la teoria della stima classica e Bayesiana, fino alla filtrazione ottima, la discretizzazione dei sistemi dinamici, e infine i protocolli di consenso e controllo distribuito su grafi.

Ogni sezione è concepita per guidare il lettore attraverso la transizione cruciale tra il mondo analogico/fisico e l'universo digitale/computazionale, evidenziando le limitazioni introdotte dalle comunicazioni reali (perdite di pacchetti, ritardi di quantizzazione, scheduling) e le soluzioni algoritmiche per mitigarne l'impatto sul comportamento di sistema.

2 Capitolo 10: I Processi di Misura e la Caratterizzazione dell'Incertezza

Qualsiasi problema di controllo o stima dello stato in un sistema autonomo distribuito si basa fondamentalmente sulla disponibilità di misure provenienti dall'ambiente fisico.

2.1 Definizioni Formali Metrologiche (VIM)

Secondo il *Vocabolario Internazionale di Metrologia* (VIM), è essenziale definire formalmente gli attori del processo di misura:

Definizione 2.1 (Misura). *Il processo di ottenere sperimentalmente uno o più valori di una grandezza che possono essere ragionevolmente attribuiti a una grandezza stessa.*

Definizione 2.2 (Misurando). *La grandezza specifica che si intende misurare (ad esempio, la temperatura di un fluido o la posizione cartesiana di un robot).*

Definizione 2.3 (Risultato della Misura). *L'insieme di valori attribuiti a un misurando, unitamente a qualsiasi altra informazione pertinente disponibile. Essa non può essere rappresentata da un singolo numero, ma deve includere l'incertezza associata.*

Definizione 2.4 (Incertezza). *Parametro non negativo che caratterizza la dispersione dei valori quantitativi attribuiti a un misurando, basato sulle informazioni utilizzate.*

Dal punto di vista formale, definendo l'insieme delle possibili manifestazioni di una proprietà fisica nel mondo empirico come Q e la classe dei simboli nel mondo simbolico come Z , il processo di misura η mappa la realtà fisica nel mondo simbolico:

$$\eta : Q \rightarrow Z, \quad z = \eta(q) \quad (1)$$

2.2 Modellazione Matematica del Sensore e Calibrazione

Un sensore (o trasduttore) converte un fenomeno fisico in un segnale misurabile (tipicamente tensione V o corrente I). Ciascun dispositivo reale introduce imperfezioni di fabbricazione e sensibilità a grandezze di influenza esterne (temperatura, umidità, usura).

I parametri metrologici fondamentali che caratterizzano un sensore sono:

- **Accuratezza (Accuracy):** Grado di concordanza tra il valore medio di misure ripetute e il valore vero del misurando. Essa è influenzata dagli errori sistematici (bias).
- **Precisione (Precision):** Grado di concordanza tra risultati di misure ripetute sullo stesso oggetto sotto specifiche condizioni. Essa esprime la dispersione (errori casuali).
- **Risoluzione (Resolution):** Il più piccolo incremento che il sensore è in grado di rilevare (correlato alla quantizzazione digitale).
- **Linearità (Linearity):** La capacità del sensore di mantenere una relazione lineare tra l'ingresso fisico e l'uscita elettrica.

La **calibrazione** ha l'obiettivo di compensare l'errore sistematico (bias) determinando la mappa inversa dall'uscita del sensore al misurando. Supponiamo di raccogliere n misure di calibrazione z_i in corrispondenza di ingressi noti u_i . Vogliamo determinare un modello polinomiale di grado q :

$$z_i \approx \hat{a}_0 + \hat{a}_1 u_i + \hat{a}_2 u_i^2 + \cdots + \hat{a}_q u_i^q \quad (2)$$

In forma matriciale, definendo il vettore delle misure $z \in \mathbb{R}^n$, la matrice di regressione $U \in \mathbb{R}^{n \times (q+1)}$ e il vettore dei parametri di calibrazione da stimare $a \in \mathbb{R}^{q+1}$:

$$z = Ua + \epsilon \quad (3)$$

La soluzione ai minimi quadrati per determinare i coefficienti ottimi $\hat{a}$ minimizza la somma dei quadrati dei residui $J(a) = (z - Ua)^T(z - Ua)$:

$$\hat{a} = \arg \min_a J(a) = (U^T U)^{-1} U^T z = U^\dagger z \quad (4)$$

dove $U^\dagger$ rappresenta la pseudo-inversa di Moore-Penrose. La calibrazione riduce al minimo l'errore sistematico, migliorando l'accuratezza del sensore. La precisione, invece, deve essere gestita tramite algoritmi di stima.

2.3 Valutazione dell'Incertezza secondo la Guida GUM

La guida *Guide to the Expression of Uncertainty in Measurement* (GUM) stabilisce che, una volta compensati gli effetti sistematici, le letture del sensore devono essere modellate come realizzazioni di una variabile casuale. Esistono due metodologie standard per valutare l'incertezza:

1. **Valutazione di Tipo A:** Si basa sull'analisi statistica di una serie di osservazioni ripetute. Data una sequenza di n misure indipendenti $z_1, \dots, z_n$, la migliore stima del misurando è la media aritmetica $\bar{z}$:

$$\bar{z} = \frac{1}{n} \sum_{i=1}^n z_i \quad (5)$$

L'incertezza standard associata alla singola misura è stimata tramite lo scarto quadratico medio campionario $s(z)$:

$$s(z) = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (z_i - \bar{z})^2} \quad (6)$$

L'incertezza standard della media $\bar{z}$ (che rappresenta il nostro stimatore) decresce all'aumentare del numero di campioni n , secondo la legge:

$$u(\bar{z}) = \frac{s(z)}{\sqrt{n}} \quad (7)$$

2. **Valutazione di Tipo B:** Si applica quando non è possibile effettuare misure ripetute o non si ha accesso ai dati grezzi. Si ricorre ad altre fonti informative (specifiche del costruttore, certificati di calibrazione precedenti, dati storici). Se il costruttore specifica che l'errore massimo è limitato nell'intervallo $\pm\tau$, in assenza di altre informazioni si applica il principio di massima entropia assumendo una PDF uniforme nell'intervallo $[T_m - \tau, T_m + \tau]$. L'incertezza standard associata è:

$$u(z) = \frac{\tau}{\sqrt{3}} \quad (8)$$

Quando sono presenti contributi di Tipo A e Tipo B, l'incertezza standard combinata $u_c(z)$ si calcola come:

$$u_c(z) = \sqrt{u_A(z)^2 + u_B(z)^2} \quad (9)$$

3 Capitolo 11: Fondamenti di Statistica e Propagazione degli Errori

La modellazione stocastica richiede un formalismo matematico rigoroso basato sulla teoria della probabilità e dei processi aleatori.

3.1 Assiomi di Kolmogorov e Teorema di Bayes

Dato uno spazio campionario S e un evento $A \subseteq S$, la probabilità $\Pr[A]$ deve soddisfare i tre assiomi di Kolmogorov:

1. $\Pr[A] \geq 0 \quad \forall A$.
2. $\Pr[S] = 1$.
3. Se $A_i \cap A_j = \emptyset$ per $i \neq j$ (eventi mutuamente esclusivi), allora $\Pr[\bigcup A_i] = \sum \Pr[A_i]$.

La probabilità condizionata di un evento A dato il verificarsi di un evento B (con $\Pr[B] > 0$) è definita come:

$$\Pr[A|B] = \frac{\Pr[A \cap B]}{\Pr[B]} \quad (10)$$

Da questa definizione si ricava direttamente la legge delle probabilità congiunte $\Pr[A \cap B] = \Pr[A|B] \Pr[B] = \Pr[B|A] \Pr[A]$, che porta alla formulazione del **Teorema di Bayes**:

$$\Pr[A_i|B] = \frac{\Pr[B|A_i] \Pr[A_i]}{\Pr[B]} = \frac{\Pr[B|A_i] \Pr[A_i]}{\sum_j \Pr[B|A_j] \Pr[A_j]} \quad (11)$$

Il teorema di Bayes costituisce la colonna portante dell'inferenza statistica, in quanto permette di aggiornare la conoscenza a priori ($\Pr[A_i]$) alla luce dell'evidenza sperimentale fornita dai dati osservati ($\Pr[B|A_i]$), ottenendo la probabilità a posteriori ($\Pr[A_i|B]$).

3.2 Variabili Casuali, Momenti Statistici e PDF Multidimensionali

Una variabile casuale x associa un numero reale a ciascun esito di un esperimento aleatorio. Essa è caratterizzata dalla sua funzione di distribuzione cumulativa (CDF) $P(x) = \Pr[X \leq x]$ e, nel caso continuo, dalla sua funzione di densità di probabilità (PDF) $p(x) = \frac{dP(x)}{dx}$.

Le proprietà di centralità e dispersione di una PDF sono descritte dai suoi **momenti**:

- **Valore Atteso (Media):** Operatore lineare definito come:

$$\mu = E\{x\} = \int_{-\infty}^{+\infty} xp(x)dx \quad (12)$$

- **Varianza:** Misura della dispersione attorno alla media:

$$\sigma^2 = V\{x\} = E\{(x - \mu)^2\} = \int_{-\infty}^{+\infty} (x - \mu)^2 p(x)dx = E\{x^2\} - \mu^2 \quad (13)$$

Nel caso di vettori di variabili casuali congiuntamente distribuite $x = [x_1, \dots, x_n]^T \in \mathbb{R}^n$, definiamo:

- **PDF congiunta:** $p(x_1, \dots, x_n)$.
- **PDF marginale** di un sottoinsieme di variabili (ottenuta integrando sulle restanti):

$$p_1(x_1) = \int_{-\infty}^{+\infty} p(x_1, x_2)dx_2 \quad (14)$$

- **PDF condizionata** (che esprime la dipendenza stocastica):

$$p(x_1|x_2) = \frac{p(x_1, x_2)}{p_2(x_2)} \quad (15)$$

Il Teorema di Bayes per le PDF si formula come:

$$p(x|z) = \frac{p(z|x)p(x)}{p(z)} = \frac{p(z|x)p(x)}{\int_{-\infty}^{+\infty} p(z|x)p(x)dx} \quad (16)$$

La correlazione lineare tra le componenti del vettore x è racchiusa nella **matrice di covarianza** $\Sigma_x \in \mathbb{R}^{n \times n}$:

$$\Sigma_x = C\{x\} = E\{(x - \mu_x)(x - \mu_x)^T\} = \begin{bmatrix} \sigma_1^2 & \text{Cov}(x_1, x_2) & \dots & \text{Cov}(x_1, x_n) \\ \text{Cov}(x_2, x_1) & \sigma_2^2 & \dots & \text{Cov}(x_2, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(x_n, x_1) & \text{Cov}(x_n, x_2) & \dots & \sigma_n^2 \end{bmatrix} \quad (17)$$

La matrice di covarianza è simmetrica e semidefinita positiva. Se le variabili sono linearmente indipendenti, Σ_x è diagonale. Se le variabili sono congiuntamente gaussiane ($x \sim \mathcal{N}(\mu_x, \Sigma_x)$), l'assenza di correlazione implica l'indipendenza stocastica.

3.3 Teorema del Limite Centrale e Propagazione degli Errori

Il **Teorema del Limite Centrale** afferma che la somma di un numero sufficientemente elevato di variabili casuali indipendenti e identicamente distribuite (i.i.d.), ciascuna con media e varianza finite, tende a distribuirsi secondo una PDF gaussiana, indipendentemente dalla forma della PDF originaria delle singole variabili. Questo giustifica l'uso ubiquitario della distribuzione normale per modellare i rumori di misura fisici.

Se un vettore di misure $y \in \mathbb{R}^m$ è legato allo stato interno $x \in \mathbb{R}^n$ e a un vettore di rumori $\epsilon \in \mathbb{R}^k$ tramite una relazione non lineare del tipo:

$$y = g(x) + f(\epsilon) \quad (18)$$

risulta complesso calcolare analiticamente la PDF esatta di y , anche ipotizzando rumori gaussiani. È possibile approssimare la propagazione della media e della covarianza linearizzando localmente la funzione f tramite l'espansione di Taylor al primo ordine attorno al valore atteso del rumore μ_ϵ :

$$f(\epsilon) \approx f(\mu_\epsilon) + J_\epsilon(\epsilon - \mu_\epsilon) \quad (19)$$

dove $J_\epsilon \in \mathbb{R}^{m \times k}$ rappresenta la **matrice Jacobiana** della trasformazione non lineare, definita come:

$$J_\epsilon = \left. \frac{\partial f(\epsilon)}{\partial \epsilon} \right|_{\epsilon=\mu_\epsilon} \quad (20)$$

Sostituendo l'approssimazione lineare, ricaviamo le relazioni per la media e la covarianza propagate:

$$\mu_y = E\{y\} \approx g(x) + f(\mu_\epsilon) \quad (21)$$

$$\Sigma_y = C\{y\} \approx J_\epsilon \Sigma_\epsilon J_\epsilon^T \quad (22)$$

Questo metodo costituisce la base per la propagazione dell'incertezza nei sistemi non lineari ed è impiegato direttamente nel filtro di Kalman esteso (EKF).

4 Capitolo 12: Algoritmi di Stima e Approcci Bayesiani

La stima consiste nel ricostruire un parametro o uno stato non direttamente accessibile x a partire da un vettore di misure rumorose z .

4.1 Classificazione dei Problemi di Stima

Dato un modello lineare $z = Hx$, dove $z \in \mathbb{R}^m$ e $x \in \mathbb{R}^n$:

- **Caso Sovradeterminato** ($m > n$): Vi sono più misure che incognite. Il problema ammette soluzione ottima approssimata minimizzando una norma dell'errore (minimi quadrati).
- **Caso Determinato** ($m = n$): Esiste un'unica soluzione se H è invertibile.
- **Caso Sottodeterminato** ($m < n$): Vi sono infinite soluzioni. Per isolarne una è necessario introdurre informazioni a priori (regolarizzazione o vincoli bayesiani).

4.2 Proprietà degli Stimatori, CRLB e Fisher Information

Un'importante distinzione risiede nel considerare il parametro da stimare x come una costante deterministica ignota (approccio frequentista o Fisheriano) o come una variabile casuale (approccio Bayesiano).

Definizione 4.1 (Stimatore Non Distorto o Unbiased). *Uno stimatore $\hat{x}(z)$ è non distorto se il suo valore atteso coincide con il parametro vero x per ogni possibile valore di x :*

$$E\{\hat{x}\} = x \quad \forall x \quad (23)$$

Se $E\{\hat{x}\} \neq x$, si definisce la *distorsione (bias)* come $b(x) = E\{\hat{x}\} - x$.

L'errore quadratico medio (MSE) di uno stimatore generico è legato alla sua varianza e al bias dalla relazione:

$$\text{MSE}(\hat{x}) = E\{(\hat{x} - x)^2\} = V\{\hat{x}\} + b(x)^2 \quad (24)$$

Se lo stimatore è non distorto, minimizzare l'MSE equivale a minimizzare la varianza. Lo stimatore non distorto che raggiunge la varianza minima per qualsiasi valore di x è denominato **MVUE** (Minimum Variance Unbiased Estimator).

La minima varianza raggiungibile da un qualsiasi stimatore non distorto è limitata inferiormente dal **Cramer-Rao Lower Bound** (CRLB):

$$V\{\hat{x}\} \geq I^{-1}(x) \quad (25)$$

dove $I(x)$ è la **Matrice d'Informazione di Fisher**, definita come:

$$I(x) = -E\left\{\frac{\partial^2 \ln p(z|x)}{\partial x^2}\right\} = E\left\{\left(\frac{\partial \ln p(z|x)}{\partial x}\right)^2\right\} \quad (26)$$

La quantità di informazione di Fisher misura la sensibilità della PDF delle misure rispetto a variazioni del parametro da stimare: maggiore è la curvatura della log-verosimiglianza $\ln p(z|x)$ (informazione elevata), minore sarà l'incertezza della stima. Uno stimatore che soddisfa il CRLB con uguaglianza è detto *efficiente*.

4.3 Teorema di Gauss-Markov e Stimatore BLUE

Qualora non si conosca la PDF esatta dei rumori, ma si posseggano informazioni solo sui primi due momenti (media e covarianza), non è possibile ricavare l'MVUE ottimo. Si ricorre quindi alla ricerca del **BLUE** (Best Linear Unbiased Estimator), vincolando lo stimatore ad essere lineare nelle misure ($\hat{x} = Lz$).

Teorema 4.1 (Gauss-Markov). *Dato il modello lineare di misura $z = Hx + w$, con rumore a media nulla $E\{w\} = 0$ e covarianza nota $C\{w\} = R$, il BLUE (ovvero lo stimatore lineare, non distorto a varianza minima) è unico ed è espresso da:*

$$\hat{x}_{BLUE} = (H^T R^{-1} H)^{-1} H^T R^{-1} z \quad (27)$$

La matrice di covarianza dell'errore di stima associata è:

$$P = C\{\hat{x}_{BLUE}\} = (H^T R^{-1} H)^{-1} \quad (28)$$

Si osservi che:

- Se il rumore w è effettivamente gaussiano, il BLUE coincide con l'MVUE ottimo globale e raggiunge il CRLB.
- Se il rumore non è gaussiano, il BLUE rimane la scelta ottima tra tutti gli stimatori lineari, sebbene possano esistere stimatori non lineari con prestazioni superiori.

4.4 Approccio Bayesiano e Caso Gaussiano Multidimensionale

Se il parametro x è trattato come variabile casuale con una PDF a priori $p(x)$ nota, l'approccio Bayesiano sfrutta la PDF a posteriori $p(x|z)$ per formulare la stima.

Teorema 4.2 (Equazioni Fondamentali della Stima Lineare). *Si considerino due vettori di variabili casuali, lo stato $x \in \mathbb{R}^n$ e le misure $z \in \mathbb{R}^m$, distribuiti congiuntamente secondo una PDF Gaussiana multidimensionale:*

$$\begin{bmatrix} x \\ z \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu_x \\ \mu_z \end{bmatrix}, \begin{bmatrix} P_{xx} & P_{xz} \\ P_{zx} & P_{zz} \end{bmatrix} \right) \quad (29)$$

La PDF condizionata $p(x|z)$ è anch'essa Gaussiana, $x|z \sim \mathcal{N}(\hat{x}_{MMSE}, P_{x|z})$, dove la media condizionata (coincidente con lo stimatore MMSE e MAP) e la covarianza condizionata sono espresse da:

$$\hat{x}_{MMSE} = E\{x|z\} = \mu_x + P_{xz} P_{zz}^{-1} (z - \mu_z) \quad (30)$$

$$P_{x|z} = C\{x|z\} = P_{xx} - P_{xz} P_{zz}^{-1} P_{zx} \quad (31)$$

Queste equazioni sono di fondamentale importanza:

1. La stima ottima $\hat{x}_{MMSE}$ è una combinazione lineare tra l'informazione a priori μ_x e la deviazione della misura reale rispetto alla sua predizione a priori $(z - \mu_z)$, pesata dal guadagno ottimo $K = P_{xz} P_{zz}^{-1}$.
2. La covarianza a posteriori $P_{x|z}$ è inferiore (in senso matriciale) rispetto alla covarianza a priori P_{xx} , a testimonianza dell'informazione estratta dalla misura. Inoltre, essa **non dipende dalla specifica misura z realizzata**, ma solo dalle covarianze a priori.

5 Capitolo 13: Stimatori Lineari e Non Lineari (Kalman, EKF, UKF)

Questa sezione analizza l'implementazione pratica degli algoritmi di stima in sistemi dinamici, partendo dai minimi quadrati ricorsivi fino ad arrivare ai filtri di Kalman lineari e non lineari.

5.1 I Minimi Quadrati Pesati (WLS) Batch e Ricorsivi

Il metodo dei minimi quadrati pesati (WLS) per parametri non casuali minimizza l'indice di costo quadratico pesato $J(x) = (z - Hx)^T W (z - Hx)$, dove la matrice di peso simmetrica e definita positiva W è solitamente posta pari a R^{-1} (inverso della covarianza del rumore) per pesare maggiormente le misure più precise. La soluzione batch è:

$$\hat{x}_{WLS} = (H^T W H)^{-1} H^T W z \quad (32)$$

In un'applicazione in tempo reale, raccogliere tutte le misure ed eseguire la stima in modalità batch diventa rapidamente proibitivo dal punto di vista computazionale (richiede la memorizzazione di vettori di dimensioni crescenti e l'inversione di matrici sempre più grandi). È necessario disporre di una formulazione ricorsiva. Ipotizziamo di possedere la stima $\hat{x}(k)$ e la sua covarianza $P(k)$ basate sulle misure fino al tempo k . All'istante $k+1$ si rende disponibile una nuova misura $z(k+1) = H(k+1)x + \epsilon(k+1)$, con errore a media nulla e covarianza $R(k+1)$. L'aggiornamento ricorsivo si ottiene applicando il Lemma di inversione matriciale:

$$(A + BCB^T)^{-1} = A^{-1} - A^{-1}B(B^T A^{-1}B + C^{-1})^{-1}B^T A^{-1} \quad (33)$$

Definendo il guadagno di aggiornamento $W(k+1)$ e la covarianza dei residui $S(k+1)$, le equazioni ricorsive del WLS risultano:

$$S(k+1) = H(k+1)P(k)H(k+1)^T + R(k+1)W(k+1) = P(k)H(k+1)^T S(k+1)^{-1} \hat{x}(k+1) = \hat{x}(k) + W(k+1)e(k+1)$$

Il termine $e(k+1) = z(k+1) - H(k+1)\hat{x}(k)$ è denominato *residuo* o *innovazione*, e rappresenta la discrepanza tra la misura reale e la predizione basata sullo stato stimato precedente.

5.2 Il Filtro di Kalman Lineare (KF)

Il Filtro di Kalman rappresenta l'estensione ottima della stima Bayesiana a sistemi dinamici lineari tempo-varianti espressi in forma di spazio di stato.

Consideriamo il sistema stocastico a tempo discreto:

$$\begin{cases} x(k+1) = A(k)x(k) + B(k)u(k) + G(k)\nu(k) \\ z(k) = H(k)x(k) + \epsilon(k) \end{cases} \quad (34)$$

dove $\nu(k) \sim \mathcal{N}(0, Q(k))$ è il rumore di processo (modello) e $\epsilon(k) \sim \mathcal{N}(0, R(k))$ è il rumore di misura, entrambi modellati come processi stocastici bianchi gaussiani e tra loro indipendenti.

Il filtro opera alternando due fasi principali ad ogni passo temporale:

1. **Fase di Predizione (Model-based):** Proietta in avanti lo stato stimato e la covarianza dell'errore sfruttando il modello dinamico del sistema (apriori).
2. **Fase di Aggiornamento (Measurement-based):** Corregge la predizione apriori sulla base della nuova misura acquisita, calcolando il guadagno ottimo di Kalman (aposteriori).

Le equazioni complete del Filtro di Kalman discreto sono:

$$\hat{x}(k+1)^- = A(k)\hat{x}(k) + B(k)u(k)P(k+1)^- = A(k)P(k)A(k)^T + G(k)Q(k)G(k)^T$$

2. Fase di Aggiornamento:

$$S(k+1) = H(k+1)P(k+1)^-H(k+1)^T + R(k+1) \quad (35)$$

$$W(k+1) = P(k+1)^-H(k+1)^TS(k+1)^{-1} \quad (36)$$

$$\hat{x}(k+1) = \hat{x}(k+1)^- + W(k+1)(z(k+1) - H(k+1)\hat{x}(k+1)^-) \quad (37)$$

$$P(k+1) = (I - W(k+1)H(k+1))P(k+1)^- \quad (38)$$

5.2.1 Derivazione Matematica del Guadagno Ottimo

Il guadagno di Kalman $W(k+1)$ viene determinato per minimizzare la varianza dell'errore di stima a posteriori, il che equivale a minimizzare la traccia della matrice di covarianza a posteriori $\text{Tr}(P(k+1))$.

La covarianza a posteriori espressa in forma generica (valida per qualsiasi guadagno W) è descritta dalla **Forma di Joseph**:

$$P = (I - WH)P^-(I - WH)^T + WRW^T \quad (39)$$

Questa formulazione, sebbene più costosa dal punto di vista computazionale rispetto alla classica formula di aggiornamento, garantisce la simmetria e la semidefinizione positiva di P anche in presenza di errori di arrotondamento numerico a precisione finita.

Sviluppando i prodotti nella forma di Joseph:

$$P = P^- - WHP^- - P^-H^TW^T + W(HP^-H^T + R)W^T = P^- - WHP^- - P^-H^TW^T + WSW^T \quad (40)$$

Calcoliamo la derivata della traccia di P rispetto a W , sfruttando le identità dell'algebra matriciale $\frac{\partial \text{Tr}(WA)}{\partial W} = A^T$ e $\frac{\partial \text{Tr}(WAW^T)}{\partial W} = 2WA$ (con A simmetrica):

$$\frac{\partial \text{Tr}(P)}{\partial W} = -2(HP^-)^T + 2WS = -2P^-H^T + 2WS \quad (41)$$

Imponendo la condizione di ottimo (derivata nulla):

$$-2P^-H^T + 2WS = 0 \implies W = P^-H^TS^{-1} \quad (42)$$

che rappresenta esattamente l'espressione del guadagno ottimo del Filtro di Kalman.

Se il sistema è lineare, tempo-invariante ($A(k) = A$, $H(k) = H$), completamente osservabile e controllabile, e i rumori sono stazionari, la covarianza $P(k)$ converge a un valore di regime stazionario P_∞ che soddisfa l'**Equazione Algebrica di Riccati a Tempo Discreto** (DARE):

$$P_\infty = AP_\infty A^T + GQG^T - AP_\infty H^T(HP_\infty H^T + R)^{-1}HP_\infty A^T \quad (43)$$

In questo scenario, il guadagno di Kalman converge a un valore costante di regime, abbattendo drasticamente lo sforzo computazionale online.

5.3 Il Filtro di Kalman Esteso (EKF)

La maggior parte dei sistemi fisici reali presenta dinamiche non lineari. Consideriamo il sistema:

$$\begin{cases} x(k+1) = f_k(x(k), u(k)) + \nu(k) \\ z(k) = h_k(x(k)) + \epsilon(k) \end{cases} \quad (44)$$

con f_k e h_k funzioni non lineari differenziabili. Il Filtro di Kalman Esteso (EKF) affronta la non-linearità applicando una linearizzazione locale tramite sviluppo di Taylor al primo ordine attorno alla stima corrente dello stato ad ogni passo temporale.

Definiamo le matrici Jacobiane del sistema:

$$A(k) = \left. \frac{\partial f_k(x, u)}{\partial x} \right|_{x=\hat{x}(k), u=u(k)} \quad (45)$$

$$H(k+1) = \left. \frac{\partial h_{k+1}(x)}{\partial x} \right|_{x=\hat{x}(k+1)^-} \quad (46)$$

Le equazioni dell'EKF mantengono la medesima struttura del filtro lineare, ma utilizzano le funzioni non lineari per la propagazione dello stato stimato e le matrici Jacobiane per la propagazione della covarianza e il calcolo del guadagno:

$$\hat{x}(k+1)^- = f_k(\hat{x}(k), u(k))P(k+1)^- = A(k)P(k)A(k)^T + Q(k)$$

2. Fase di Aggiornamento:

$$S(k+1) = H(k+1)P(k+1)^-H(k+1)^T + R(k+1) \quad (47)$$

$$W(k+1) = P(k+1)^-H(k+1)^TS(k+1)^{-1} \quad (48)$$

$$\hat{x}(k+1) = \hat{x}(k+1)^- + W(k+1)(z(k+1) - h_{k+1}(\hat{x}(k+1)^-)) \quad (49)$$

$$P(k+1) = (I - W(k+1)H(k+1))P(k+1)^- \quad (50)$$

Sebbene l'EKF sia ampiamente utilizzato, presenta notevoli svantaggi:

1. L'approssimazione al primo ordine trascura i termini di grado superiore, il che può indurre forti bias di stima e portare all'incoerenza o alla divergenza del filtro qualora le non-linearità siano pronunciate.
2. Il calcolo analitico delle Jacobiane può essere complesso e soggetto a errori di implementazione software.

5.4 Il Filtro di Kalman Unscented (UKF) e l'Incertezza Polare-Cartesiana

Per superare i limiti dell'EKF senza ricorrere al calcolo delle Jacobiane, il Filtro di Kalman Unscented (UKF) utilizza la *Unscented Transformation*. Invece di approssimare le funzioni non lineari, l'UKF approssima la PDF dello stato campionandola in modo deterministico tramite un insieme minimo di punti scelti (detti **Sigma Points**). Questi punti vengono fatti propagare direttamente attraverso le equazioni non lineari del sistema, permettendo di ricostruire la media e la covarianza a posteriori con un'accuratezza garantita fino al secondo ordine dello sviluppo di Taylor.

L'assoluta necessità di disporre di approssimazioni di ordine superiore al primo in presenza di forti non-linearità può essere dimostrata analiticamente tramite il classico esempio della conversione di coordinate da polari (acquisite da un sensore LiDAR) a cartesiane.

Sia $p_m = [r_m, \theta_m]^T$ la misura polare fornita dal sensore, affetta da rumori additivi indipendenti a media nulla $\eta_r \sim \mathcal{U}(-r^*, r^*)$ e $\eta_\theta \sim \mathcal{U}(-\theta^*, \theta^*)$ con varianze σ_r^2 e σ_θ^2 :

$$r_m = r + \eta_r, \quad \theta_m = \theta + \eta_\theta \quad (51)$$

La mappa di conversione non lineare in coordinate cartesiane $z = [x, y]^T$ è:

$$z = \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} r_m \cos \theta_m \\ r_m \sin \theta_m \end{bmatrix} = h(p_m) \quad (52)$$

Se applicassimo l'approssimazione al primo ordine impiegata nell'EKF per calcolare il valore atteso di z assumendo il valore vero dello stato $p = [1, \pi/2]^T$, otterremmo:

$$\mu_{z,1^o\text{ordine}} = h(E\{p_m\}) = h(p) = \begin{bmatrix} 1 \cdot \cos(\pi/2) \\ 1 \cdot \sin(\pi/2) \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad (53)$$

Calcoliamo ora il valore atteso analitico esatto della componente y , sfruttando l'indipendenza statistica di r_m e θ_m e la simmetria della PDF del rumore:

$$\begin{aligned} E\{y\} &= E\{r_m \sin \theta_m\} = E\{(r + \eta_r) \sin(\theta + \eta_\theta)\} \\ &= E\{r + \eta_r\} E\{\sin \theta \cos \eta_\theta + \cos \theta \sin \eta_\theta\} \\ &= r \sin \theta E\{\cos \eta_\theta\} + r \cos \theta E\{\sin \eta_\theta\} \end{aligned} \quad (54)$$

Dato che $\theta = \pi/2$, abbiamo $\sin \theta = 1$ e $\cos \theta = 0$. Inoltre, poiché il rumore η_θ è distribuito uniformemente nell'intervallo $[-\theta^*, \theta^*]$, calcoliamo l'integrale:

$$E\{\cos \eta_\theta\} = \int_{-\theta^*}^{\theta^*} \cos(\eta_\theta) \frac{1}{2\theta^*} d\eta_\theta = \frac{\sin \theta^*}{\theta^*} \quad (55)$$

Quindi il valore atteso esatto è:

$$E\{y\} = r \frac{\sin \theta^*}{\theta^*} \quad (56)$$

Poiché per qualsiasi $\theta^* > 0$ si ha $\frac{\sin \theta^*}{\theta^*} < 1$, l'approssimazione al primo ordine ($\mu_y = 1$) commette un errore sistematico (bias) non nullo.

Proviamo ora ad espandere fino al secondo ordine lo sviluppo di Taylor di $h(p_m)$ attorno a $E\{p_m\}$:

$$\mu_{z,2^o\text{ordine}} \approx h(p) + \frac{1}{2} E \left\{ \frac{\partial^2 h(p_m)}{\partial \theta_m^2} \Big|_p \eta_\theta^2 \right\} = \begin{bmatrix} 0 \\ 1 \end{bmatrix} + \frac{1}{2} \sigma_\theta^2 \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 - \frac{\sigma_\theta^2}{2} \end{bmatrix} \quad (57)$$

Poiché l'espansione di Taylor di $\sin \theta^*$ arrestata al terzo ordine è $\sin \theta^* \approx \theta^* - \frac{(\theta^*)^3}{6}$, abbiamo $\frac{\sin \theta^*}{\theta^*} \approx 1 - \frac{(\theta^*)^2}{6} = 1 - \frac{\sigma_\theta^2}{2}$ (essendo la varianza della PDF uniforme $\sigma_\theta^2 = \frac{(\theta^*)^2}{3}$).

Questo dimostra analiticamente che l'approssimazione al secondo ordine cattura perfettamente l'effetto della non-linearità sulla media, evitando l'introduzione di bias sistematici che inficerebbero la consistenza del filtro di stima. L'UKF, lavorando fino al secondo ordine, garantisce questa precisione in modo nativo e senza necessità di derivazione analitica delle Jacobiane.

6 Capitolo 14: Metodi di Stima Avanzati - Massima Verosimiglianza (MLE)

L'approccio di Massima Verosimiglianza rappresenta il pilastro della teoria della stima classica o frequentista, in cui il parametro da stimare θ è trattato come un vettore di costanti ignote.

6.1 La Likelihood Function e la Formulazione dell'Ottimo

Dato un vettore di osservazioni sperimentali $D = \{d_1, \dots, d_N\}$ modellate come variabili casuali i.i.d. distribuite secondo una PDF $p(d, \theta)$ parametrizzata dal vettore θ , la **Funzione di Verosimiglianza** (Likelihood Function, LF) è espressa come:

$$L(D, \theta) = \prod_{k=1}^N p(d_k, \theta) \quad (58)$$

Lo stimatore di massima verosimiglianza $\hat{\theta}_{ML}$ seleziona il valore dei parametri che massimizza la probabilità di aver ottenuto lo specifico insieme di osservazioni effettivamente registrate:

$$\hat{\theta}_{ML} = \arg \max_{\theta} L(D, \theta) \quad (59)$$

Poiché la funzione logaritmo naturale è strettamente monotona crescente, massimizzare $L(D, \theta)$ equivale a massimizzare la **Log-Verosimiglianza** (Log-Likelihood), che trasforma il prodotto in una sommatoria, semplificando la trattazione analitica e numerica:

$$\ln L(D, \theta) = \sum_{k=1}^N \ln p(d_k, \theta) \quad (60)$$

La condizione necessaria per la ricerca del massimo, nel caso di funzioni differenziabili, si ottiene annullando il gradiente (chiamato **Score Vector**):

$$\left. \frac{\partial \ln L(D, \theta)}{\partial \theta} \right|_{\theta=\hat{\theta}_{ML}} = 0 \quad (61)$$

6.2 Esempio Analitico: Distribuzione di Poisson

La distribuzione di Poisson è largamente utilizzata per modellare il conteggio di eventi discreti in un intervallo temporale (es. arrivo di messaggi in una coda o guasti hardware). La probabilità di osservare il valore intero non negativo y_i dato il parametro di tasso medio $\theta > 0$ è:

$$f(y_i, \theta) = \frac{e^{-\theta} \theta^{y_i}}{y_i!} \quad (62)$$

Data una serie di N osservazioni indipendenti, la log-verosimiglianza si scrive come:

$$\ln L(D, \theta) = \sum_{i=1}^N \ln \left(\frac{e^{-\theta} \theta^{y_i}}{y_i!} \right) = -N\theta + \ln(\theta) \sum_{i=1}^N y_i - \sum_{i=1}^N \ln(y_i!) \quad (63)$$

Calcoliamo la derivata rispetto a θ e imponiamo l'annullamento per trovare lo stimatore MLE:

$$\frac{\partial \ln L(D, \theta)}{\partial \theta} = -N + \frac{1}{\theta} \sum_{i=1}^N y_i = 0 \implies \hat{\theta}_{ML} = \frac{1}{N} \sum_{i=1}^N y_i \quad (64)$$

Lo stimatore MLE per la distribuzione di Poisson coincide quindi con la media aritmetica delle osservazioni.

6.3 Proprietà Asintotiche dello Stimatore MLE

Sotto opportune condizioni di regolarità della PDF, lo stimatore MLE gode di proprietà asintotiche di assoluto rilievo al tendere del numero di misure all'infinito ($N \rightarrow \infty$):

1. **Consistenza:** Lo stimatore converge quasi certamente al valore vero del parametro: $\lim_{N \rightarrow \infty} \hat{\theta}_{ML} = \theta_0$. Di conseguenza, è asintoticamente non distorto.
2. **Efficienza Asintotica:** Lo stimatore raggiunge il Cramer-Rao Lower Bound, ovvero la sua varianza asintotica è la minima possibile.
3. **Normalità Asintotica:** La distribuzione dello stimatore tende a una normale centrata sul valore vero con covarianza pari all'inverso dell'informazione di Fisher:

$$\sqrt{N}(\hat{\theta}_{ML} - \theta_0) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{I(\theta_0)}\right) \quad (65)$$

4. **Invarianza:** Se $\hat{\theta}_{ML}$ è lo stimatore MLE di θ , e $g(\theta)$ è una funzione continua (non necessariamente iniettiva), allora $g(\hat{\theta}_{ML})$ è lo stimatore MLE di $g(\theta)$. Questa proprietà è esclusiva dell'MLE (non vale ad esempio per l'MVUE in cui le trasformazioni non lineari introducono bias).

6.4 Determinazione Numerica dell'Ottimo

Qualora non esista una soluzione analitica in forma chiusa per l'equazione dello Score, è necessario ricorrere ad algoritmi di ottimizzazione numerica iterativi:

- **Newton-Raphson:** Sfrutta la matrice Hessiana $H(k)$ valutata ad ogni passo per aggiornare la stima nella direzione del massimo:

$$\hat{\theta}_{k+1} = \hat{\theta}_k - H^{-1}(\hat{\theta}_k) \frac{\partial \ln L(D, \theta)}{\partial \theta} \Big|_{\hat{\theta}_k} \quad (66)$$

- **Metodo dello Scoring di Fisher:** Sostituisce la matrice Hessiana (complicata da calcolare ad ogni passo) con il suo valore atteso negativo, ovvero la matrice d'informazione di Fisher $I(\theta)$:

$$\hat{\theta}_{k+1} = \hat{\theta}_k + I^{-1}(\hat{\theta}_k) \frac{\partial \ln L(D, \theta)}{\partial \theta} \Big|_{\hat{\theta}_k} \quad (67)$$

- **Berndt-Hall-Hall-Hausman (BHHH):** Approssima l'informazione di Fisher tramite il prodotto esterno del vettore Score calcolato per le singole osservazioni, evitando del tutto il calcolo delle derivate seconde:

$$I(\theta) \approx \sum_{i=1}^N \left(\frac{\partial \ln p(d_i, \theta)}{\partial \theta} \right) \left(\frac{\partial \ln p(d_i, \theta)}{\partial \theta} \right)^T \quad (68)$$

6.5 Applicazione ai Segnali: Stima dei Parametri di una Sinusoide

Consideriamo il problema di stimare l'ampiezza A , la frequenza f_0 e la fase ϕ di un segnale sinusoidale affetto da rumore bianco gaussiano (WGN) con varianza σ^2 :

$$x[n] = A \cos(2\pi f_0 n + \phi) + w[n], \quad n = 0, \dots, N-1 \quad (69)$$

Questo problema, non lineare nei parametri a causa della frequenza f_0 , può essere riformulato definendo i parametri lineari $\alpha_1 = A \cos \phi$ e $\alpha_2 = -A \sin \phi$:

$$x[n] = \alpha_1 \cos(2\pi f_0 n) + \alpha_2 \sin(2\pi f_0 n) + w[n] \quad (70)$$

In forma matriciale, definendo $H(f_0) = [c, s]$ dove $c = [\cos(2\pi f_0 n)]^T$ e $s = [\sin(2\pi f_0 n)]^T$, la minimizzazione dei residui quadratici porta a determinare α tramite minimi quadrati lineari una volta nota la frequenza:

$$\hat{\alpha} = (H(f_0)^T H(f_0))^{-1} H(f_0)^T x \quad (71)$$

Sostituendo la soluzione ottima dei minimi quadrati nell'indice di costo, si dimostra che la massimizzazione della log-verosimiglianza rispetto alla frequenza f_0 equivale a massimizzare la funzione:

$$J_3(f_0) = x^T H (H^T H)^{-1} H^T x \quad (72)$$

Assumendo che la frequenza f_0 non sia prossima a 0 o a 0.5, i vettori colonna di H sono quasi ortogonali, per cui possiamo approssimare la matrice $H^T H \approx \frac{N}{2} I$. Questo permette di ridurre il problema alla massimizzazione del **Periodogramma** (trasformata discreta di Fourier delle misure):

$$\hat{f}_0 = \arg \max_f \left| \sum_{n=0}^{N-1} x[n] e^{-j2\pi f n} \right|^2 \quad (73)$$

Una volta ricavata numericamente la frequenza ottima $\hat{f}_0$ tramite una ricerca su griglia o algoritmo di Newton, i restanti parametri si ricavano per invarianza:

$$\hat{A} = \sqrt{\hat{\alpha}_1^2 + \hat{\alpha}_2^2} = \frac{2}{N} \left| \sum_{n=0}^{N-1} x[n] e^{-j2\pi \hat{f}_0 n} \right|, \quad \hat{\phi} = \arctan \left(\frac{-\hat{\alpha}_2}{\hat{\alpha}_1} \right) \quad (74)$$

7 Capitolo 15: Un Esempio di Stima Distribuita e Incoerenza nelle Covarianze

La stima dello stato in un sistema multi-agente richiede la condivisione di informazioni locali tra nodi per migliorare la precisione complessiva della flotta. Tuttavia, l'interazione ingenua tramite misure relative introduce severe problematiche di correlazione incrociata.

7.1 Modellazione e Stima Intermittente

Consideriamo due agenti x_1 e x_2 che si muovono lungo una linea retta con dinamica lineare di primo ordine:

$$x_i(k+1) = x_i(k) + a_i d_i(k) + b_i \epsilon_i(k) \quad (75)$$

con incertezza di processo bianca gaussiana $\epsilon_i \sim \mathcal{N}(0, \sigma_i^2)$.

Ogni $n_i \geq 1$ passi temporali, ciascun agente riceve una misura della propria posizione assoluta da un sensore esogeno (es. GPS):

$$z_i(k) = x_i(k) + \eta_i(k), \quad \eta_i \sim \mathcal{N}(0, \xi_i^2) \quad (76)$$

Poiché le misure assolute sono disponibili solo in modo intermittente, l'agente esegue alternativamente la sola predizione del modello (dead reckoning, in cui la covarianza $P_i(k)$ cresce linearmente a causa dell'integrazione del rumore di processo) o l'aggiornamento ottimo di Kalman non appena la misura assoluta si rende disponibile.

7.2 Misure Relative e l'Insorgenza della Correlazione

Supponiamo ora che gli agenti effettuino anche misure di distanza relativa tra di loro (es. tramite un sensore LiDAR a bordo di x_1 che rileva la posizione di x_2):

$$z_{12}(k) = x_2(k) - x_1(k) + \eta_{12}(k), \quad \eta_{12} \sim \mathcal{N}(0, \xi_{12}^2) \quad (77)$$

Se analizzassimo il sistema multi-agente dal punto di vista di un'architettura centralizzata, lo stato complessivo sarebbe $x = [x_1, x_2]^T$ con matrice di covarianza congiunta P :

$$P = \begin{bmatrix} P_{11} & P_{12} \\ P_{21} & P_{22} \end{bmatrix} \quad (78)$$

Inizialmente, i due agenti sono stocasticamente indipendenti, per cui la matrice di covarianza è diagonale ($P_{12} = 0$).

Quando l'agente 1 effettua la misura relativa z_{12} , l'aggiornamento dello stato centralizzato utilizza il vettore di misura con matrice di uscita $H = [-1, 1]$. Calcolando l'aggiornamento aposteriori della covarianza $P(k+1) = (I - WH)P^-(k+1)$:

$$P(k+1) = \frac{1}{P_{11}^- + P_{22}^- + \xi_{12}^2} \begin{bmatrix} P_{11}^-(P_{22}^- + \xi_{12}^2) & P_{11}^- P_{22}^- \\ P_{22}^- P_{11}^- & P_{22}^-(P_{11}^- + \xi_{12}^2) \end{bmatrix} \quad (79)$$

Si noti che l'elemento fuori diagonale $P_{12} = \frac{P_{11}^- P_{22}^-}{P_{11}^- + P_{22}^- + \xi_{12}^2}$ diventa strettamente maggiore di zero. **La misura relativa ha creato una correlazione stocastica tra lo stato stimato del robot 1 e lo stato stimato del robot 2.**

7.3 Incoerenza della Stima e Sottostima dell'Incertezza

In un sistema distribuito decentralizzato reale, ciascun agente esegue il proprio filtro di Kalman locale a bordo e non ha accesso alla matrice di covarianza congiunta globale P , ma traccia esclusivamente la propria covarianza locale P_i .

Se l'agente 2 effettua successivamente una misura relativa dell'agente 1 e la processa per aggiornare la propria stima locale assumendo che le due stime siano stocasticamente indipendenti (ovvero assumendo implicitamente $P_{12} = 0$), commette un errore metodologico critico. Il filtro di stima locale utilizzerà informazioni vecchie e correlate trattandole come se fossero nuove e indipendenti.

Le conseguenze di questo comportamento sono deleterie:

1. **Inconsistenza (Inconsistency):** Il filtro di Kalman locale aggiornerà le proprie covarianze locali decrementandole fittiziamente ad ogni passo di misura relativa. Il robot crederà di avere una stima estremamente precisa (covarianza calcolata molto piccola), mentre l'errore di stima reale rispetto allo stato fisico vero sarà molto elevato.
2. **Divergenza:** Poiché lo spazio delle coordinate assolute della flotta non è osservabile mediante le sole misure relative (esiste un autovalore pari a zero nello spazio $x_1 + x_2$, associato al dead reckoning collettivo), l'incertezza reale del sistema cresce illimitatamente, portando alla divergenza della stima rispetto alla realtà fisica.

Per risolvere l'inconsistenza nella localizzazione cooperativa distribuita, è necessario implementare algoritmi di disaccoppiamento della covarianza (come la *Covariance Intersection* o la stima decentralizzata basata su fattori di sconto dell'informazione) che garantiscano l'invarianza del filtro rispetto a correlazioni non tracciabili.

8 Capitolo 16: Sistemi Digitali e Discretizzazione di Sistemi Continui

Nei moderni sistemi di controllo distribuito, un elaboratore digitale interagisce con un impianto fisico a tempo continuo tramite convertitori analogico-digitali (ADC/Sampler) e convertitori digitale-analogici (DAC/Hold).

8.1 Metodi di Discretizzazione di Sistemi Lineari SISO

Si consideri un sistema lineare tempo-continuo descritto dalla funzione di trasferimento $G(s) = \frac{Y(s)}{U(s)}$ o dall'equazione differenziale associata. La discretizzazione consiste nel mappare il modello nel dominio discreto del tempo (operatore di shift q o variabile complessa z).

Esistono tre metodi fondamentali basati sull'approssimazione numerica dell'integrale del segnale:

Metodo di Discretizzazione	Sostituzione di s	Mappatura di Stabilità
Eulero in Avanti (Forward)	$s \leftarrow \frac{q-1}{\Delta t}$	Può rendere instabili sistemi stabili
Eulero all'Indietro (Backward)	$s \leftarrow \frac{q-1}{q\Delta t}$	Può rendere stabili sistemi instabili
Trapezoidale / Tustin (Bilineare)	$s \leftarrow \frac{2}{\Delta t} \frac{q-1}{q+1}$	Preserva esattamente la stabilità

Figure 1: Confronto delle tecniche di discretizzazione lineare.

L'approssimazione trapezoidale (Tustin) deriva dall'approssimazione del primo ordine di Padé del ritardo temporale $z = e^{s\Delta t}$:

$$z \approx \frac{1 + s\Delta t/2}{1 - s\Delta t/2} \implies s = \frac{2}{\Delta t} \frac{z - 1}{z + 1} \quad (80)$$

Essa mappa la regione di stabilità a tempo continuo ($\text{Re}(s) < 0$) esattamente all'interno del cerchio unitario del piano discreto ($|z| < 1$).

8.2 Risposta Libera, Risposta Forzata e la Discretizzazione dello Stato

Si consideri la rappresentazione nello spazio di stato di un sistema lineare tempo-invariante a tempo continuo:

$$\dot{x}(t) = Ax(t) + Bu(t) \quad (81)$$

La soluzione generale dell'equazione differenziale matriciale è data dalla sovrapposizione della risposta libera (unforced) e della risposta forzata (forced):

$$x(t) = e^{A(t-t_0)}x(t_0) + \int_{t_0}^t e^{A(t-\tau)}Bu(\tau)d\tau \quad (82)$$

dove l'esponenziale di matrice (matrice di transizione dello stato) è definita dalla serie esponenziale:

$$\Phi(t) = e^{At} = \sum_{i=0}^{\infty} \frac{A^i t^i}{i!} = I + At + \frac{A^2 t^2}{2} + \dots \quad (83)$$

Ipotizzando l'applicazione di un campionatore periodico con tempo di campionamento Δt e un mantentore d'ordine zero (ZOH, che mantiene l'ingresso costante nell'intervallo d'inter-campionamento $u(t) = u(k)$ per $k\Delta t \leq t < (k+1)\Delta t$), la soluzione esatta discretizzata all'istante $k+1$ è:

$$x(k+1) = A_d x(k) + B_d u(k) \quad (84)$$

dove:

$$A_d = e^{A\Delta t} \quad (85)$$

$$B_d = \left(\int_0^{\Delta t} e^{A\tau} d\tau \right) B = A^{-1}(e^{A\Delta t} - I)B \quad (\text{se } A \text{ è invertibile}) \quad (86)$$

Qualora si utilizzi l'approssimazione di Eulero in avanti (SDR), si assume invece $A_d \approx I + A\Delta t$ e $B_d \approx B\Delta t$, introducendo un errore di approssimazione dell'ordine di $O(\Delta t^2)$.

8.3 Discretizzazione del Rumore di Processo

Qualora il sistema a tempo continuo sia stocastico, ovvero guidato da un rumore bianco continuo $\tilde{\nu}(t)$ a media nulla con densità spettrale di potenza $V(t)$:

$$\dot{x}(t) = Ax(t) + Bu(t) + G\tilde{\nu}(t) \quad (87)$$

il corrispondente rumore discreto equivalente $\nu(k)$ che agisce nel modello discretizzato è definito dall'integrale stocastico nell'intervallo di campionamento:

$$\nu(k) = \int_{k\Delta t}^{(k+1)\Delta t} e^{A((k+1)\Delta t - \tau)} G\tilde{\nu}(\tau) d\tau \quad (88)$$

La media di $\nu(k)$ rimane nulla, $E\{\nu(k)\} = 0$, mentre la sua matrice di covarianza equivalente Q_d risulta espressa dall'integrale:

$$Q_d = E\{\nu(k)\nu(k)^T\} = \int_0^{\Delta t} e^{A(\Delta t - \tau)} G V(\tau) G^T e^{A^T(\Delta t - \tau)} d\tau \quad (89)$$

Questa relazione evidenzia come un tempo di campionamento Δt più ampio provochi una maggiore penetrazione dell'incertezza del modello stocastico continuo nel sistema discreto, deteriorando le prestazioni di stima.

8.4 Campionamento di Riemann e di Lebesgue

Esistono due paradigmi principali per l'acquisizione dei dati campionati:

1. **Campionamento di Riemann (Time-triggered):** La digitalizzazione avviene a istanti temporali fissi e periodici ($t_k = k\Delta t$). È la tecnica standard, che semplifica la progettazione matematica del sistema ma sollecita inutilmente la rete trasmettendo dati anche quando lo stato non varia.
2. **Campionamento di Lebesgue (Event-triggered):** La digitalizzazione viene attivata esclusivamente quando lo stato del sistema fisico attraversa una determinata soglia di variazione spaziale ($\|x(t) - x(t_k)\| \geq \delta$). Ottimizza l'uso della banda di rete e riduce il consumo energetico dei nodi, ma richiede un formalismo matematico asincrono più complesso.

9 Capitolo 17: Teoria del Consenso Lineare su Grafi

La teoria del consenso lineare descrive i meccanismi mediante i quali un insieme di nodi autonomi scambia informazioni a livello locale per convergere in modo asintotico su uno stato comune, senza l'ausilio di un'autorità centrale.

9.1 Modellazione Algebrica del Consenso e Matrici Stocastiche

Si consideri una rete di n agenti, ciascuno caratterizzato da uno stato scalare $x_i(k)$. Il protocollo di consenso lineare in tempo discreto prevede che ciascun agente aggiorni il proprio stato calcolando una media pesata del proprio stato e di quello dei propri vicini comunicanti:

$$x_i(k+1) = \sum_{j=1}^n q_{ij} x_j(k) \quad (90)$$

In forma vettoriale:

$$x(k+1) = Qx(k) \quad (91)$$

Per garantire la convergenza verso uno stato di accordo comune stabile, la matrice di transizione $Q \in \mathbb{R}^{n \times n}$ deve soddisfare specifiche proprietà algebriche:

Definizione 9.1 (Matrice Stocastica). *Una matrice Q è stocastica (o riga-stocastica) se tutti i suoi elementi sono non negativi ($q_{ij} \geq 0$) e la somma degli elementi di ciascuna riga è pari a 1:*

$$\sum_{j=1}^n q_{ij} = 1 \quad \forall i \implies Q1 = 1 \quad (92)$$

dove $1 = [1, \dots, 1]^T$ è il vettore di soli uni. Di conseguenza, 1 è un autovalore di Q con autovettore destro pari a 1.

Definizione 9.2 (Matrice Doppia Stocastica). *Una matrice Q è doppiamente stocastica se è stocastica e la somma degli elementi di ciascuna colonna è pari a 1:*

$$1^T Q = 1^T \quad (93)$$

La natura della matrice Q determina il valore di convergenza asintotica:

- Se Q è semplicemente stocastica, gli agenti convergeranno ad un accordo comune α , ma tale valore sarà una combinazione pesata arbitraria degli stati iniziali: $\lim_{k \rightarrow \infty} x(k) = (\beta^T x(0))1$, dove β^T è l'autovettore sinistro associato all'autovalore 1 ($\beta^T Q = \Gamma^T$).
- Se Q è doppiamente stocastica, l'accordo asintotico converge esattamente al valore medio aritmetico degli stati iniziali (**Average Consensus**):

$$\lim_{k \rightarrow \infty} x_i(k) = \frac{1}{n} \sum_{j=1}^n x_j(0) \quad \forall i \implies \lim_{k \rightarrow \infty} Q^k = \frac{1}{n} 11^T = J_a \quad (94)$$

9.2 Teoria dei Grafi e Proprietà del Laplaciano

Le connessioni di comunicazione all'interno della rete multi-agente sono modellate formalmente mediante un grafo diretto o indiretto $G = (\mathcal{N}, \mathcal{E})$, dove $\mathcal{N} = \{1, \dots, n\}$ rappresenta l'insieme dei nodi (agenti) e $\mathcal{E} \subseteq \mathcal{N} \times \mathcal{N}$ l'insieme degli archi (canali di comunicazione attivi).

Le matrici algebriche fondamentali associate al grafo sono:

- **Matrice di Adiacenza** $A = [a_{ij}] \in \mathbb{R}^{n \times n}$: dove $a_{ij} > 0$ se l'agente j trasmette all'agente i , altrimenti $a_{ij} = 0$.
- **Matrice di Grado** $D = \text{diag}(d_{in}(i)) \in \mathbb{R}^{n \times n}$: dove $d_{in}(i) = \sum_j a_{ij}$ rappresenta il grado in ingresso del nodo.
- **Matrice Laplaciana** $L \in \mathbb{R}^{n \times n}$: definita come:

$$L = D - A \quad (95)$$

La matrice Laplaciana gode di importanti proprietà spettrali:

1. La somma delle righe di L è nulla, per cui $L1 = 0$. Il valore 0 è sempre un autovalore di L con autovettore associato 1.
2. Tutti gli autovalori non nulli di L hanno parte reale positiva (teorema dei dischi di Gershgorin).
3. **Spanning Tree (Albero di Copertura)**: Il grafo possiede uno spanning tree diretto se esiste almeno un nodo radice in grado di raggiungere tutti gli altri nodi della rete attraverso cammini orientati.

Teorema 9.1. *L'autovalore 0 della matrice Laplaciana L ha molteplicità algebrica pari a 1 (è semplice) se e solo se il grafo di comunicazione associato possiede uno spanning tree diretto. In tal caso, il protocollo di consenso continuo $\dot{x}(t) = -Lx(t)$ converge asintoticamente ad un consenso comune stabile.*

9.3 Velocità di Convergenza e Progettazione Ottima dei Pesi

La velocità con cui la flotta converge verso lo stato di consenso è governata dal secondo autovalore più grande (in modulo) della matrice di transizione, denominato **Essential Spectral Radius** $\rho_2(Q)$. Il fattore di convergenza asintotico è espresso come:

$$r_a = \rho(Q - J_a) = |\lambda_2(Q)| \quad (96)$$

Minore è il valore di $|\lambda_2(Q)|$, più rapida sarà la convergenza esponenziale della rete.

Per progettare una matrice Q compatibile con una data topologia di rete non completa che garantisca l'average consensus, si ricorre a due metodologie di design dei pesi a livello locale:

1. **Pesi di Massimo Grado (Max-Degree)**: Scelta semplice basata esclusivamente sul numero massimo di nodi presenti nella rete:

$$q_{ij} = \begin{cases} \epsilon = \frac{1}{n_d} & \text{se } (j, i) \in \mathcal{E} \text{ e } i \neq j \\ 1 - d_{in}(i)\epsilon & \text{se } i = j \\ 0 & \text{altrimenti} \end{cases} \quad (97)$$

dove $n_d > \max_i d(i)$. Garantisce l'average consensus per grafi non orientati connessi, ma offre una velocità di convergenza ridotta.

2. **Pesi di Metropolis-Hastings**: Consente una convergenza significativamente più rapida sfruttando l'informazione locale dei gradi dei nodi vicini:

$$q_{ij} = \begin{cases} \frac{1}{\max(d(i), d(j))+1} & \text{se } (j, i) \in \mathcal{E} \text{ e } i \neq j \\ 1 - \sum_{k \neq i} q_{ik} & \text{se } i = j \\ 0 & \text{altrimenti} \end{cases} \quad (98)$$

10 Capitolo 18: Algoritmi di Stima Distribuita (Distributed WLS e DKF)

Gli algoritmi di stima distribuita fondono i concetti di filtrazione ottima (sviluppati nei Capitoli 12 e 13) con la teoria del consenso su grafi (Capitolo 17) per consentire a ciascun agente di ricostruire lo stato del sistema globale senza un'unità centrale di calcolo.

10.1 Algoritmo dei Minimi Quadrati Pesati Distribuito (D-WLS)

Si consideri il problema di stimare un parametro deterministico costante globale x mediante una rete multi-agente in cui ciascun agente effettua misure locali rumorose $z_i = H_i x + \epsilon_i$ con covarianza dell'errore R_i . La soluzione ottima centralizzata dei minimi quadrati pesati (WLS) è:

$$\hat{x}_{WLS} = \left(\sum_{i=1}^n H_i^T R_i^{-1} H_i \right)^{-1} \left(\sum_{i=1}^n H_i^T R_i^{-1} z_i \right) \quad (99)$$

Per calcolare questa quantità in modo distribuito, definiamo due quantità cumulative globali:

$$F = \sum_{i=1}^n H_i^T R_i^{-1} H_i \quad (\text{Matrice d'Informazione di Fisher globale}) \quad (100)$$

$$a = \sum_{i=1}^n H_i^T R_i^{-1} z_i \quad (\text{Vettore d'Informazione globale}) \quad (101)$$

Ciascun agente può inizializzare localmente lo stato di due algoritmi di consenso sulla media paralleli con i propri contributi informativi locali:

$$F_i(0) = H_i^T R_i^{-1} H_i, \quad a_i(0) = H_i^T R_i^{-1} z_i \quad (102)$$

Eseguendo cicli di consenso lineare basati su una matrice di transizione doppiamente stocastica Q , si dimostra che asintoticamente (o dopo un numero sufficiente di passi q):

$$F_i(q) \rightarrow \frac{F}{n}, \quad a_i(q) \rightarrow \frac{a}{n} \quad (103)$$

Ciascun agente può quindi calcolare la stima ottima centralizzata globale dei minimi quadrati in modo totalmente decentralizzato semplicemente dividendo le due quantità locali (essendo il fattore n semplificato dal rapporto):

$$\hat{x}_i = F_i(q)^{-1} a_i(q) = \left(\frac{F}{n} \right)^{-1} \left(\frac{a}{n} \right) = F^{-1} a = \hat{x}_{WLS} \quad (104)$$

10.2 Filtro di Kalman Distribuito (DKF)

L'estensione della stima distribuita a sistemi dinamici stocastici tempo-varianti si realizza mediante il **Filtro di Kalman Distribuito** (DKF), formulato prevalentemente nel dominio dello spazio delle informazioni (Information Filter).

Ciascun agente esegue autonomamente la fase di predizione a bordo utilizzando il proprio modello dinamico locale. Per la fase di aggiornamento, anziché scambiare direttamente le stime e le misure (che violerebbe l'ipotesi di indipendenza stocastica a causa delle correlazioni introdotte, vedi Capitolo 15), gli agenti convertono le stime nel dominio dell'informazione ed eseguono passi di consenso locale per aggregare il vettore d'informazione e la matrice di Fisher globale:

$$a_i(k+1, 0) = H_i^T R_i^{-1} z_i(k+1) F_i(k+1, 0) = H_i^T R_i^{-1} H_i$$

2. Esecuzione di q cicli di consenso sulla media doppiamente stocastico:

$$a_i(k+1, m+1) = \sum_{j=1}^n q_{ij} a_j(k+1, m) \quad (105)$$

$$F_i(k+1, m+1) = \sum_{j=1}^n q_{ij} F_j(k+1, m) \quad (106)$$

3. Aggiornamento ottimo dello stato e della covarianza locale (conoscendo n):

$$P_i(k+1) = \left((P_i(k+1)^-)^{-1} + nF_i(k+1, q) \right)^{-1} \quad (107)$$

$$\hat{x}_i(k+1) = P_i(k+1) \left((P_i(k+1)^-)^{-1} \hat{x}_i(k+1)^- + na_i(k+1, q) \right) \quad (108)$$

Il DKF permette di ottenere prestazioni identiche a quelle del filtro di Kalman centralizzato globale se il numero di iterazioni di consenso q tende all'infinito. Nella pratica, un valore di q compreso tra 3 e 10 garantisce un'approssimazione eccellente con un carico di comunicazione di rete contenuto.

11 Capitolo 19: Introduzione al Controllo Distribuito

Il controllo distribuito unisce le leggi di attuazione locale con le dinamiche collettive della flotta per raggiungere obiettivi globali di pianificazione o di mantenimento di una specifica formazione geometrica.

11.1 Controllo di Copertura Distribuita mediante Tassellazione di Voronoi

Il problema della copertura distribuita consiste nel disporre una flotta di n agenti mobili in uno spazio operativo $S \subset \mathbb{R}^2$ in modo da massimizzare la capacità di sensing collettiva rispetto a una determinata densità di probabilità $\phi(q)$ (che descrive l'importanza delle varie aree del territorio).

Dato un insieme di posizioni degli agenti $p = [p_1, \dots, p_n]^T$, lo spazio S viene partizionato mediante la **Tassellazione di Voronoi** in n celle poligonali convesse V_i :

$$V_i(p) = \{q \in S \mid \|q - p_i\| \leq \|q - p_j\| \quad \forall j \neq i\} \quad (109)$$

Definiamo la **Massa** M_{V_i} e il **Centroide** C_{V_i} della singola cella V_i :

$$M_{V_i} = \int_{V_i} \phi(q) dq, \quad C_{V_i} = \frac{1}{M_{V_i}} \int_{V_i} q \phi(q) dq \quad (110)$$

L'indice di costo di copertura da minimizzare (che funge anche da candidato forte come funzione di Lyapunov per il sistema multi-agente) è espresso come:

$$H(p) = \sum_{i=1}^n \int_{V_i} \|q - p_i\|^2 \phi(q) dq \quad (111)$$

Assumendo che gli agenti mobili siano governati da una cinematica ad integratore singolo ($\dot{p}_i = u_i$), calcoliamo la derivata parziale dell'indice H rispetto alle posizioni p_i applicando la regola di Leibniz. Grazie alla proprietà geometrica per cui i confini delle celle di Voronoi sono equidistanti dai generatori adiacenti, i termini derivanti dalla variazione dei confini delle celle si cancellano reciprocamente, fornendo la formulazione pulita:

$$\frac{\partial H}{\partial p_i} = -2 \int_{V_i} (q - p_i) \phi(q) dq = -2M_{V_i}(C_{V_i} - p_i) \quad (112)$$

Imponendo la **legge di controllo proporzionale di Lloyd**:

$$\dot{p}_i = u_i = -k_p(p_i - C_{V_i}), \quad k_p > 0 \quad (113)$$

la derivata temporale della funzione di Lyapunov $H(p)$ risulta:

$$\dot{H} = \sum_{i=1}^n \frac{\partial H}{\partial p_i} \dot{p}_i = -2k_p \sum_{i=1}^n M_{V_i} \|p_i - C_{V_i}\|^2 \leq 0 \quad (114)$$

Essendo $\dot{H}$ semidefinita negativa, per il **Principio di Invarianza di LaSalle** lo stato del sistema converge asintoticamente all'insieme invariante in cui $\dot{H} = 0$, ovvero la flotta converge stabilmente verso la configurazione ottimale in cui ciascun robot si posiziona esattamente nel centroide della propria cella di Voronoi (*Centroidal Voronoi Configuration*).

11.2 Consenso del Secondo Ordine per Sistemi Posizione-Velocità

Qualora i veicoli debbano essere modellati mediante dinamiche del secondo ordine (considerando sia la posizione $\xi_i \in \mathbb{R}^d$ che la velocità $\zeta_i \in \mathbb{R}^d$):

$$\begin{cases} \dot{\xi}_i = \zeta_i \\ \dot{\zeta}_i = u_i \end{cases} \quad (115)$$

si applica il protocollo di consenso lineare del secondo ordine:

$$u_i = - \sum_{j=1}^n g_{ij} k_{ij} [(\xi_i - \xi_j) + \gamma(\zeta_i - \zeta_j)] \quad (116)$$

dove $\gamma > 0$ è un parametro di smorzamento progettato ad hoc, e $L = [l_{ij}]$ è il Laplaciano associato alla topologia.

In forma matriciale, l'evoluzione dinamica complessiva è regolata dal sistema:

$$\begin{bmatrix} \dot{\xi} \\ \dot{\zeta} \end{bmatrix} = \Gamma \begin{bmatrix} \xi \\ \zeta \end{bmatrix}, \quad \Gamma = \begin{bmatrix} 0 & I \\ -L & -\gamma L \end{bmatrix} \quad (117)$$

La convergenza del sistema del secondo ordine è significativamente più delicata rispetto al caso del primo ordine, in quanto possono innescarsi oscillazioni instabili se il coefficiente γ non è tarato opportunamente rispetto agli autovalori del Laplaciano.

Teorema 11.1. *Il protocollo del secondo ordine raggiunge il consenso asintotico su posizione e velocità ($\xi_i \rightarrow \xi_j$ e $\zeta_i \rightarrow \zeta_j \rightarrow 0$) se e solo se il grafo ha uno spanning tree e il fattore di smorzamento γ soddisfa la disuguaglianza:*

$$\gamma > \max_{\mu_i \neq 0} \sqrt{\frac{2}{|\mu_i| \cos\left(\frac{\pi}{2} - \arctan \frac{-\operatorname{Re}(\mu_i)}{\operatorname{Im}(\mu_i)}\right)}} \quad (118)$$

dove μ_i rappresentano gli autovalori della matrice Laplaciana $-L$.

11.3 Problematiche Reali di Comunicazione nei Sistemi Multi-Agente

Nelle applicazioni ingegneristiche reali, le ipotesi ideali di comunicazione istantanea e senza perdite decadono rapidamente. Le simulazioni numeriche evidenziano forti impatti dovuti a:

- **Perdita Casuale di Pacchetti:** Modellata mediante prove bernoulliane indipendenti (monete truccate basate su distribuzioni gaussiane filtrate). Si dimostra che l'algoritmo di consenso è estremamente robusto: la convergenza si mantiene stabile anche con tassi di consegna dei pacchetti inferiori al 50%, subendo esclusivamente un rallentamento esponenziale del tempo di convergenza t_{conv} .
- **Scheduling Round Robin (TDMA):** Se i nodi condividono lo stesso canale fisico e devono trasmettere sequenzialmente, la dimensione del quanto temporale di allocazione t_q influisce drasticamente sulle prestazioni. All'aumentare di t_q , il tempo di convergenza cresce a causa del ritardo indotto sugli altri agenti in attesa, fino a provocare l'instabilità del controllo discreto se il quanto supera la soglia critica del tempo di discretizzazione.
- **Limited Communication Range (Raggio di Comunicazione):** Se il raggio di sensing R_c dei sensori di prossimità scende al di sotto del valore nominale della formazione geometrica desiderata, la topologia del grafo si frammenta e le prestazioni di mantenimento della formazione (valutate mediante l'RMSE del rapporto diagonale/lato della forma quadrata della flotta) degradano bruscamente fino a perdersi del tutto.